About Discrimination in Hiring

20180490 이재헌

Introduction: KLIPS

Data source: Korean Labor and Income Panel Study(KLIPS),
 7th wave

KLIPS is:

- A longitudinal study of a representative sample of Korean households and individuals living in urban areas.
- Conducted annually to track the characteristics of households as well as the economic activities, labor movement, income, expenditures, education, job training, and social activities of individuals.

Introduction: Details on the data

• Data Description: Participants' experiences of hiring discrimination were measured.

How the data looks like

index	disc_hire	gender	age	edu_cat	mariage	emp_fin	income_quartile	birth_region	health	disability	residence	disc_wage	disc_jobedu	disc_promotion	disc_resign
0	1.0	0	3	1	2	0	0	0	1	0	1	1	0	0	0
1	0.0	1	3	1	2	1	1	0	2	0	1	0	0	0	0
2	0.0	1	1	2	0	1	1	0	2	0	1	0	0	0	0
3	0.0	1	1	2	1	0	3	0	1	0	1	0	0	0	0
4	1.0	0	3	0	1	0	1	0	2	0	1	0	0	0	0

Introduction: Details on the data

	Variable name	Description	Possible answers
1	disc_hire	Response to the question, "Have you ever experienced discrimination in getting hired?"	0:'No', 1:'Yes', NA:'Not Applicable'
2	Gender	Gender	0:male, 1:female
3	Age	Age	0:16-24, 1:25-34, 2:35-44, 3:45-54, 4:55-64, 5:65+ years old
4	Edu_cat	Education level	0:middle school graduate or less, 1:high school graduate, 2:college graduate or more
5	Marriage	Marital status	O:never married, 1:currently married, 2:previously married
6	Emp_fin	Employment status	0:permanent, 1:non-permanent
7	Income_quartile	Total household income divided by the square root of the number of	0:Q1, 1:Q2, 3:Q3, 4:Q4
		household members	(4 categories based on the quartiles)
8	Birth_region	Birth region	1:Jeolla-do, 0:other regions
9	Self-rated health	Response to the question, "How would you rate your health?"	0:'very good', 1:'good', 2:'poor', 3:'very poor'
10	Disability	Response to the question "Do you have any impairment or disability?"	0:'No', 1:'Yes'
11	Residence	Residential areas	1:Seoul, 2:Pusan, 3:Daegu, 4:Daejeon, 5:Incheon, 6:Gwangju, 7:Ulsan, 8:Kyunggi, 9:Kangwon, 10:Choongbuk, 11:Choongnam, 12:Jeonbuk, 13:Jeonnam, 14:Kyungbuk, 15:Kyungnam
12	disc_wage	Experience of discrimination in receiving income	0:'No', 1:'Yes', 2:'Not Applicable'
13	disc_jobedu	Experience of discrimination in training	0:'No', 1:'Yes', 2:'Not Applicable'
14	disc_promotion	Experience of discrimination in getting promoted	0:'No', 1:'Yes', 2:'Not Applicable'
15	disc_resign	Experience of discrimination in being fired	0:'No', 1:'Yes', 2:'Not Applicable'
16	disc_edu	Experience of discrimination in obtaining higher education	0:'No', 1:'Yes', 2:'Not Applicable'
17	disc_home	Experience of discrimination at home	0:'No', 1:'Yes', 2:'Not Applicable'
18	disc_social	Experience of discrimination at general social activities	0:'No', 1:'Yes', 2:'Not Applicable'

Background (Motivation)

 The KLIPS dataset is intended to help design and implement more reasonable and accurate employment policies.

 By controlling for unobservable individual effects, it permits accurate understanding of the dynamic changes in the decision-making process and <u>behavioral pattern of</u> <u>individuals and households in response to changes in the</u> <u>environment</u> such as time and government policies.

Background (Motivation)

Examples of Use

- Understanding an individual's lifetime career path from the first job out of school to turnover and/or job separation and retirement
- O Understanding women's labor activities from the time of labor market entry to exit, along with the factors that have an impact in the process
- Understanding an individual's process of building human capital through education, training and company training, and its impact on entry into the labor market
- Understanding the impact of the government's employment policies on building human capital Investigating on dynamic changes in household economy and generational changes
- Therefore, we can make <u>better employment policies</u> and <u>understand better what factors are related to discrimination</u> in hiring by analyzing the data

Objective

Figuring out

 1. What variables are related to hiring discrimination and how they are related. (Q. 1,4,5)

2. How the data can be clustered (Q. 2,3)

Question 1

- What are the important variables that are associated with the experience of hiring discrimination?
- How are those variables related to the experience of hiring discrimination?

Q1: Data Preprocessing

- 원래는 disc_hire 가 N/A 인 사람들의 자료를 제외하고 3479명의 자료를 그대로 사용하려고 했습니다.
- 하지만 disc_wage, disc_jobedu, disc_promotion, disc_resign, disc_edu, disc_home and disc_social 의 총 7가지 variable에 Not Applicable 로 응답한 사람의 값이 2로 저장되어 있었습니다.
- No = 0, Yes = 1 이기 때문에 N/A = 2를 쓰는 것은 이치에 맞지 않다고 생각해서 데이터를 제외하려고 하였습니다. 하지만 제외할 데이터의 수가 너무 많아지고(약 1000개) disc_hire의 평균이 크게 바뀌었습니다. 그래서 대신 N/A를 0과 1 사이의 값으로 변환하기로 결정하였습니다.

Q1: Data Preprocessing - Mean Est.

- N/A 처리 방법:
- 각 variable에 대해서 N/A(=2) 를 제외한 0과 1의 값들로 평균을 낸 후, 이 평균을 N/A 대신 넣어주었습니다.
- 이렇게 하면 scaling 한 이후에 이 값들은 모두 0이 되기 때문에 regression에 영향을 주지 않을 수 있다고 생각했습니다.
- Ex) $(1, 0, 0, 2) \rightarrow (1, 0, 0, 1/3)$

Q1: Data Preprocessing - Mean Est.

Data after preprocessing

	gender	age	edu_cat	mariage	emp_fin	income_quartile	birth_region	health	disability	residence	disc_wage	disc_jobedu	disc_promotion	disc_resign
0	0	3	1	2	0	0	0	1	0	1	1.0	0.000000	0.00000	0.000000
1	1	3	1	2	1	1	0	2	0	1	0.0	0.000000	0.00000	0.000000
2	1	1	2	0	1	1	0	2	0	1	0.0	0.000000	0.00000	0.000000
3	1	1	2	1	0	3	0	1	0	1	0.0	0.000000	0.00000	0.000000
4	0	3	0	1	0	1	0	2	0	1	0.0	0.000000	0.00000	0.000000
3571	0	1	2	1	0	3	0	2	0	5	0.0	0.000000	0.00000	0.000000
3572	0	1	1	1	1	0	0	1	0	3	0.0	0.021856	0.00000	0.020421
3573	0	1	1	1	0	0	1	0	0	1	0.0	0.000000	0.00000	0.000000
3574	0	1	2	1	0	0	0	1	0	8	0.0	0.000000	0.06526	0.020421
3575	1	1	2	1	0	3	0	1	0	1	0.0	0.000000	0.00000	0.000000

- 방법 1: disc_hire와의 correlation이 높은 variable 찾기
- Correlation의 절댓값으로 정렬하였습니다.

Correaltion of disc_hire with repect to each variable

disc_wage : 0.6295803472606901 disc_social : 0.3177017098600349 disc_promotion : 0.2330898418994605 disc_resign : 0.22434538252118089 disc_jobedu : 0.21561331302082498 edu cat : -0.18122465963652767

income_quartile : -0.17947442299470145

disc_home : 0.16181032007132162 emp_fin : 0.15331820400340926 disc_edu : 0.09986301712643753 health : 0.09002393573477176 age : 0.08808585005683363

disability : 0.07985001614343912 birth_region : -0.03616662107234033

gender : 0.028481598991618836 residence : 0.023151828427013427 mariage : 0.015606196448611167

Ranking	Variable
1	disc_wage
2	disc_social
3	disc_promotion
4	disc_resign
5	disc_jobedu
6	edu_cat
7	income_quartile

Ranking	Variable
1	disc_wage
2	disc_social
3	disc_promotion
4	disc_resign
5	disc_jobedu
6	edu_cat
7	income_quartile

Disc___ variable은, 입사를 한 이후에 경험하는 것들입니다. 채용과정에서 차별을 받았으면 입사 이후에도 차별받은 경우가 많다는 것을 알수 있습니다.
 채용 과정에서 영향을 주는 것은 최종학력 (edu_cat)과 소득(income_quartile)이라고 해석할 수 있습니다.

Correaltion of disc_hire with repect to each variable

disc_wage : 0.6295803472606901 disc_social : 0.3177017098600349 disc_promotion : 0.2330898418994605 disc_resign : 0.22434538252118089 disc_jobedu : 0.21561331302082498 edu cat : -0.18122465963652767

income_quartile : -0.17947442299470145

• 학력이 낮을수록, 소득이 적을수록 입사할 때 차별을 받았다는 것을 알 수 있습니다.

- 방법 2: disc_hire와의 logistic regression 후 p value가 작은 variable 찾기
- 각 variable의 scale이 다르기 때문에 먼저 scaling 하였습니다.
- 각 variable별로 정규화를 하였습니다. $Z=rac{X-\mu}{\sigma}$

Scaled Data

3571 -0.809863	-0.826216	1.151205	0.364598	-0.555769	1.185739	-0.487481	0.886686	-0.16203	-0.266745	-0.426822	-1.569191e- 01	-2.808207e-01	-0.152124	-0.107663	-0.146478
3572 -0.809863	-0.826216	-0.159345	0.364598	1.799310	-1.655951	-0.487481	-0.587875	-0.16203	-0.706037	-0.426822	2.490930e-17	-2.808207e-01	0.000000	-0.107663	-0.146478
3573 -0.809863	-0.826216	-0.159345	0.364598	-0.555769	-1.655951	2.051361	-2.062435	-0.16203	-1.145329	-0.426822	-1.569191e- 01	-2.808207e-01	-0.152124	-0.107663	-0.146478
3574 -0.809863	-0.826216	1.151205	0.364598	-0.555769	-1.655951	-0.487481	-0.587875	-0.16203	0.392193	-0.426822	-1.569191e- 01	-5.971782e-17	0.000000	-0.107663	-0.146478
3575 1.234777	-0.826216	1.151205	0.364598	-0.555769	1.185739	-0.487481	-0.587875	-0.16203	-1.145329	-0.426822	-1.569191e- 01	-2.808207e-01	-0.152124	-0.107663	-0.146478

• Logistic Regression 을 한 후, p value가 작은 순으로 정렬했습니다.

index	coef	std err	Z	P> z ▲
disc_wage	1.3801	0.083	16.651	0.0
disc_resign	2.934	0.348	8.419	0.0
disc_home	0.2272	0.05	4.567	0.0
disc_social	0.3747	0.051	7.374	0.0
income_quartile	-0.1575	0.046	-3.42	0.001
emp_fin	0.1284	0.046	2.807	0.005
disc_jobedu	0.2425	0.086	2.814	0.005
mariage	-0.1382	0.054	-2.559	0.01
residence	0.092	0.043	2.145	0.032
age	0.1216	0.058	2.085	0.037
disc_edu	0.0683	0.05	1.362	0.173
health	0.0582	0.045	1.288	0.198
gender	-0.0518	0.045	-1.15	0.25
disc_promotion	-0.0694	0.061	-1.14	0.254
disability	0.0366	0.044	0.822	0.411
birth_region	-0.0332	0.043	-0.772	0.44
edu_cat	0.0032	0.053	0.061	0.952

- H0: coeff = 0.
- P value가 작다는 것이 무조건 important variable임을 보장하지 않지만 important variable이면 p value가 작다.

• Logistic Regression 을 한 후, p value가 작은 순으로 정렬했습니다.

results_scaled.pvalues.sort_values()

disc_wage	2.976096e-62
disc_resign	3.793729e-17
disc_social	1.655163e-13
disc_home	4.950384e-06
income_quartile	6.259342e-04
disc_jobedu	4.892201e-03
emp_fin	5.004861e-03
mariage	1.048899e-02
residence	3.191839e-02
age	3.710601e-02
disc_edu	1.731857e-01
health	1.975961e-01
gender	2.503133e-01
disc_promotion	2.544269e-01
disability	4.109147e-01
birth_region	4.400138e-01
edu_cat	9.515474e-01
dtype: float64	

Ranking	Variable
1	disc_wage
2	disc_resign
3	disc_social
4	disc_home
5	Income_quartile
6	disc_jobedu
7	emp_fin

Ranking	Variable
1	disc_wage
2	disc_resign
3	disc_social
4	disc_home
5	Income_quartile
6	disc_jobedu
7	emp_fin

index	coef
disc_wage	1.3801
disc_resign	2.934
disc_home	0.2272
disc_social	0.3747
income_quartile	-0.1575
emp_fin	0.1284
disc_jobedu	0.2425
mariage	-0.1382

- Disc___ variable은, 입사를 한 이후에 경험하는 것들입니다. 채용과정에서 차별을 받았으면 입사 이후에도 차별받은 경우가 많다는 것을 알 수 있습니다.
- 채용 과정에서 영향을 주는 것은 소득 (income_quartile)과 정규직 여부 (emp_fin)이라고 해석할 수 있습니다.
- 학력이 낮을수록, 비정규직일수록 입사할 때 차별을 받았다는 것을 알 수 있습니다.
- edu_cat의 p value는 크게 나왔습니다.

Q1: Finding Imp. Var.: Corr vs Logis.

[(Cor	re	lat	ion	

Ranking	Variable			
1	disc_wage			
2	disc_resign			
3	disc_social			
4	disc_home			
5	Income_quartile			
6	disc_jobedu			
7	emp_fin			

[Logistic Regression]

Ranking	Variable			
1	disc_wage			
2	disc_social			
3	disc_promotion			
4	disc_resign			
5	disc_jobedu			
6	edu_cat			
7	income_quartile			

- 두 방법에서 모두 disc_wage가 가장 중요한 variable이라는 것을 알 수 있습니다.
- Logistic regression의 결과가 최종 답안입니다.

Q2. PCA

- What are the important principle components (PC) that explain a large portion of variation in the given 12 explanatory?
- How would you interpret those PCs?


Q2. PCA: Preprocessing

• Q1에서와 같이 N/A data를 각 변수의 N/A(=2) 값을 제외한 평균으로 대체하였습니다.

• 그런 다음, PCA를 진행하기 위해 Scaling을 해주었습니다. (with Standard Scaler, $Z=\frac{X-\mu}{\sigma}$)


Q2. PCA: Biplot

- Interpretation on PC1
- disc_edu, disc_wage 등 직 장 내에서 차별 받았던 경험이 PC1 에 가장 많이 contribute 했음을 볼 수 있습니다.
- 또한 disc_wage, disc_edu 등 차별받았던 경험 벡터들의 방향이 유사하므로 이들의 correlation이 높음을 알 수 있 습니다. 어떤 차별을 받았으면 다른 차별도 받았을 확률이 높 다는 뜻입니다.



Q2. PCA: Biplot


- Interpretation on PC2
- Age, health, edu_cat 이 PC2 에 가장 많이 contribute 했음을 볼 수 있습니다.
- Age와 health, emp_fin의 correlation이 높습니다. 나이가 많을수록 건강하지 않고, 비정규직일 확률이 높습니다.
- 또한 income_quartile 과 edu_cat이 correlation이 높습니다. 학력이 낮을수록 수입이 낮을 확률이 높습니다.




Q2. PCA: Biplot

Interpretation on PC2

• 차별 받았던 경험 disc_wage, disc_edu 등과 age, health 등의 차별과 관계 없는 변수들 과의 correlation이 작습니다.




Q2. PCA: Explained Variance



• Criteria: Sum of variance ratio > 50% ⇒ n = 4 로 Q.3 진행

Q2. PCA: Visualization on 3D space




Q3. Clustering with PCA

- Identify subgroups (clusters) based on the 12 variables you use for PCA to answer question 2.
- Also, identify subgroups based on the important PCs you find to answer question 2.
- Compare the clustering results.

Q3. Clustering with PCA


• From Q.2, I chose n = # of PC = 4




• 눈으로 봤을 때 cluster가 보이긴 하지만, 이렇게 나눌만한 기준을 세울수 없었습니다.

• 그래서 K means clustering 방법 으로 접근하였습니다.


Q3. Clustering with PCA






- Inertia = $\sum d^2(x, c_k)$ 의 변화 비교하여 K 값 설정
- Inertia의 변화를 기준으로 K = 4로 설정 (코드 참 조)

Q3. Clustering with PCA: K means




K-Means Clustering Results with K=4 on 3D space




 K means 알고리즘을 사용해서 clustering 한 결과, 왼쪽과 같이 4개의 cluster를 형성하였습니다. (빨, 초, 파, 검)

Q3. Clustering with PCA: K means




K-Means Clustering Results with K=4 on 3D space



- 초록색: 차별 경험이 적고, 나이가 많고 건강하지 않으며, 비정규직 인 사람들
- рсз 검은색: 차별 경험이 적고, 소득이 많으며, 학력이 높은 사람들
 - 파란색: 젊고, 소득이 많고, 학력 이 높은 사람들
 - 빨간색: 차별 경험이 있는 사람들

Q3. Clustering with PCA: Hierarchical

Clustering with complete linkage hierarchical method




• Height = 7에서 tree cut

• Average, single linkage 로도 시도 해보았지만, 성능이 좋지 않았습니다.

Q3. Clustering with PCA: Hierarchical

Complete linkage tree clustering with 7 clusters




- Cluster가 총 7개 나왔습니다.
- 처음에 눈으로 봤을 때 확인했던 cluster와 비슷하게 clustering 이 되었습니다.
- 그림에서 왼쪽에 있는 cluster일 수록 차별 경험이 없는 사람들, 오른쪽에 있는 cluster일수록 차 별 경험이 많은 사람들입니다.

Q4. Discrimination Under reporting

 Is there a difference in under reporting of hiring discrimination between males and females?

Q4. Lasso Cross Validation

• Q.1 에서 사용하였던 disc_hire 가 N/A가 아닌 자료들을 training set으로 사용하여 LASSO parameter λ를 tuning 하였습니다.




• 실행 결과, λ = 0.00218 를 얻었습니다.

• 일부 LASSO parameter가 0이 된 것을 확인할 수 있습니다.

Q4. Lasso Cross Validation

ROC and AUC of LASSO



- AUC of LASSO
- = 0.88674

Q4. Random Forest Cross Validation


• Random forest 의 parameter 수의 후보: all, sqrt, log2

• "Sqrt"의 경우가 Cross validation set에서 best performance를 보였습니다.

• 따라서, model = RF(max_features='sqrt')

Q4. Random Forest Cross Validation

ROC and AUC of Random Forest



• AUC of Random Forest = 0.99887

Q4. Random Forest Prediction

• Random forest model로 예측한 결과는 아래와 같습니다.

- male_report_ratio = 0.3125
- female_report_ratio = 0.8182
- 남성의 경우, under reporting이 있는 것을 확인했습니다.
- (남성의 경우, 차별을 받는다고 말을 안 하는 경향이 있습니다.)


Q5.

 Is there an association between the experience of hiring discrimination and health?

Q5. Relationship btw disc_hire & health

Distribution of health with respect to the given groups

```
print(dist1, dist2, dist3, dist4)
[0.587898 0.30648 0.055854 0.049767] [0.527697 0.344023 0.102041 0.026239] [0.702128 0.170213 0.106383 0.021277] [0.48 0.3 0.16 0.06]
```



Q5. Relationship btw disc_hire & health

- Overall method: Chi-square test
- Result: Reject the null hypothesis
- Pairwise multiple testing method: Tukey HSD
- Results: as follows

Q5. Relationship btw disc_hire & health

Multiple	e Compa	arison of	Means -	- Tukey I	HSD, FWE	ER=0.05
group1 (group2	meandiff	p-adj	lower	upper	reject
G1 G1 G1 G2 G2 G3	G2 G3 G4 G3 G4 G4	-0.0067 0.1916 -0.1602 0.0381	0.9999 0.1961 0.3985 0.9808	0.0791 -0.2632 -0.0572 -0.4231 -0.2173 -0.156	0.2498 0.4404 0.1028 0.2936	True False False False False False

- H_0 : G2(No)=G3(N/A but Yes)
- H_0 : G3 (N/A but Yes) = G4 (N/A but No)
- 두 귀무가설 모두 reject 되어야 하지만 accept 되었다. 따라서 disc_hire와 health의 관계는 없다.

Conclusion

• Q1: 학력이 낮을수록, 비정규직일수록 입사할 때 차별을 받았다는 것을 알 수 있습니다. 따라서 이를 시정할 수 있는 제도를 만들어야 할 것입니다.

• Q4: 남성이 여성보다 차별 받는다고 말하는 경우가 적습니다. 남성이 말을 하지 않는다고 해서 차별을 받고 있지 않다고 생각하면 안 될 것입니다.

• Q5: 차별 받는 것과 건강한 정도는 유의미한 상관관계가 없습니다.

Thank you so much for listening!